

Enriquecer, recuperar o adaptar: VQA dermatológico en español con modelos visión–lenguaje eficientes

Santino Domato, Damián Di Stefano y Matías Lein

Universidad de San Andrés

Buenos Aires, Argentina

Resumen

Estudiamos generación de respuestas dermatológicas en español a partir de una consulta y una imagen clínica. El conjunto DermaVQA-IIFYI contiene varias respuestas médicas por caso, lo que produce objetivos heterogéneos. Construimos una variante enriquecida integrando, mediante un modelo de lenguaje, todas las respuestas disponibles en una única respuesta clínica concisa y la comparamos con el objetivo original de respuesta más larga. Sobre ambos objetivos evaluamos recuperación textual, inferencia *zero-shot*, adaptación QLoRA/LoRA de Qwen2.5-VL-3B-Instruct y generación aumentada por recuperación (RAG). Con un protocolo pareado por imagen, LoRA sobre el objetivo enriquecido obtiene el mejor resultado: chrF medio de 0,365, ROUGE-L de 0,254, token-F1 de 0,317 y BERTScore F1 de 0,738. En cambio, sobre respuesta larga el modelo base supera al adaptado en chrF y BERTScore. RAG mejora modestamente al modelo base enriquecido, pero suele degradar LoRA; entrenar LoRA con el mismo contexto RAG recupera BERTScore, aunque no supera al LoRA sin RAG. El estudio muestra que la consistencia del objetivo de supervisión puede ser tan importante como la estrategia de adaptación. Una auditoría exploratoria también detecta errores clínicos relevantes, por lo que estos resultados no justifican uso asistencial.

1. Introducción

La respuesta automática a consultas médicas con imágenes exige integrar evidencia visual, lenguaje clínico y señales contextuales del paciente. En dermatología, además, una misma consulta puede recibir respuestas profesionales con diagnósticos diferenciales, niveles de certeza y recomendaciones distintas. Esa variabilidad dificulta entrenar y evaluar sistemas de pregunta-respuesta visual (VQA) en español.

DermaVQA aporta consultas dermatológicas, imágenes generadas por pacientes y respuestas mul-

tilingües (Yim et al., 2024b). La tarea MEDIQA-M3G mostró que el ajuste de modelos visión–lenguaje (VLM) y la traducción pueden ser competitivos en español (Yim et al., 2024a; Bauer et al., 2024). Sin embargo, bajo recursos limitados todavía es incierto si conviene recuperar respuestas de casos similares, adaptar un VLM o combinar ambas estrategias.

Formulamos tres preguntas. **RQ1:** ¿cómo cambia el aprendizaje al usar una respuesta original larga frente a una síntesis clínica homogénea? **RQ2:** ¿la adaptación eficiente con LoRA mejora al modelo base y a la recuperación textual? **RQ3:** ¿RAG aporta evidencia útil o introduce información de otros pacientes que desvía la generación?

Nuestras contribuciones son: (i) una variante enriquecida de DermaVQA-IIFYI con una respuesta textual integrada por caso; (ii) una comparación controlada de Qwen2.5-VL-3B-Instruct (Bai et al., 2025) sobre dos objetivos, con la misma unidad por imagen y 155 actualizaciones; (iii) ablaciones de RAG tanto en inferencia como durante el fine-tuning; y (iv) un análisis cuantitativo y cualitativo de los principales modos de error.

2. Trabajo relacionado

VQA médico y dermatológico. DermaVQA fue diseñado para generación abierta y multilingüe de respuestas dermatológicas a partir de consultas e imágenes de pacientes (Yim et al., 2024b). MEDIQA-M3G reunió sistemas que combinaron VLM, traducción y adaptación al dominio (Yim et al., 2024a). Por ejemplo, Bauer et al. (2024) ajustan LLaVA-Med y traducen sus salidas al español, mientras que Thomas et al. (2024) estudian un VLM liviano ajustado para la misma tarea. Nuestro foco no es competir con el *leaderboard*, sino aislar el efecto del target textual, LoRA y RAG bajo un presupuesto pequeño.

Split	Casos	Filas por imagen
Train	842	2.473
Valid	56	157
Test	100	314
Total	998	2.944

Cuadro 1: Composición de las variantes larga y enriquecida. La expansión por imagen conserva el `encounter_id`.

Adaptación eficiente. LoRA introduce matrices de bajo rango entrenables sobre pesos congelados (Hu et al., 2022); QLoRA agrega cuantización de cuatro bits para reducir memoria sin ajustar todos los parámetros (Detrmers et al., 2023). Aplicamos estas técnicas a Qwen2.5-VL, un VLM generalista con procesamiento visual de resolución dinámica y soporte multilingüe (Bai et al., 2025).

Recuperación y generación. RAG condiciona la generación en evidencia recuperada (Lewis et al., 2020). Para similitud textual usamos TF-IDF, Sentence-BERT (Reimers and Gurevych, 2019) y Multilingual E5 (Wang et al., 2024). A diferencia de RAG factual sobre una base curada, aquí cada contexto pertenece a otro paciente; por ello evaluamos explícitamente cuándo ayuda y cuándo contamina la respuesta.

3. Datos y construcción de objetivos

Usamos el subconjunto IIYI en español con los splits oficiales corregidos: 842 casos de entrenamiento, 56 de validación y 100 de prueba. Cada caso tiene entre una y 16 imágenes. Expandimos cada encuentro a una fila por imagen para que ambos entrenamientos vean exactamente 2.473 filas de train, 157 de validación y 314 de test (Tabla 1). La pregunta concatena título y contenido de la consulta. No existen preguntas, respuestas ni rutas de imagen vacías en los artefactos finales.

Respuesta larga. Seleccionamos, para cada caso, la respuesta original en español con mayor longitud. Este objetivo preserva la redacción del foro, incluidos detalles, tratamientos y variación estilística.

Respuesta enriquecida. Realizamos una síntesis textual por cada uno de los 998 casos mediante gpt-oss-120b desplegado en Azure AI Foundry. El modelo recibió únicamente la pregunta y las respuestas originales deduplicadas; no recibió imágenes. El prompt, versión `llm_synthesis_es_v5`,

solicitó una única respuesta clínica de 60–100 palabras cuando las fuentes lo permitieran, sin agregar diagnósticos ni tratamientos no sustentados, y con incertidumbre explícita ante contradicciones. Se usó temperatura 0,2 y salida JSON estructurada. Luego repetimos la síntesis para cada imagen del caso. Esta operación reduce variación textual, pero también introduce un modelo generativo en la construcción de la referencia.

4. Metodología

4.1. Recuperación textual

Los baselines recuperan del split de entrenamiento el caso cuya pregunta es más similar y devuelven su respuesta. Comparamos TF-IDF con normalización, multilingual-e5-small y paraphrase-multilingual-MiniLM-L12-v2. Para E5 usamos los prefijos `query:` y `passage:`, embeddings normalizados y similitud coseno. Validación y test nunca ingresan al índice.

4.2. VLM base y QLoRA/LoRA

El modelo generativo es Qwen2.5-VL-3B-Instruct. La entrada contiene una imagen y la pregunta; la salida supervisada es la respuesta de la variante correspondiente. Entrenamos una época sobre 2.473 filas con batch 1, acumulación 16, $learning\ rate\ 2 \times 10^{-4}$, scheduler coseno, LoRA $r = 16$, $\alpha = 32$ y dropout 0,05. La cuantización es NF4 de cuatro bits con doble cuantización y cómputo bfloat16. Se adaptan las proyecciones de atención y las capas lineales del MLP. Ambos objetivos completan 155 pasos de optimización con semilla 42; por lo tanto, la comparación es pareada en datos visuales, modelo, hiperparámetros y cómputo.

4.3. RAG en inferencia y entrenamiento

Construimos un índice E5 sobre las 842 preguntas únicas de train. Para cada fila recuperamos los tres encuentros más cercanos y agregamos al prompt sus preguntas y respuestas. En train se excluye el propio `encounter_id` (*leave-one-out*); en validación y test se consulta exclusivamente el índice de train.

Evaluamos dos usos de ese contexto. **RAG en inferencia** mantiene el modelo base o el adapter LoRA original y solo modifica el prompt. **LoRA RAG-aware** entrena y evalúa un adapter nuevo con el mismo formato de imagen, pregunta y tres contextos, eliminando el desajuste entre entrenamiento

e inferencia. Esta última condición se ejecutó para el objetivo enriquecido.

5. Evaluación

La comparación VLM principal se realiza sobre las mismas 314 filas de test, una por imagen. Reportamos sacreBLEU corpus (Post, 2018), chrF corpus y chrF medio (Popović, 2015), ROUGE-L (Lin, 2004), token-F1 y BERTScore F1 multilingüe (Zhang et al., 2020). Las métricas de retrieval se calculan a nivel caso ($n = 100$), por lo que se presentan por separado. No seleccionamos la mejor imagen de cada encuentro.

Para el diagnóstico de errores definimos un score compuesto por el promedio no ponderado de chrF, ROUGE-L, token-F1 y BERTScore por fila. Comparamos condiciones de manera pareada y estratificamos por longitud de referencia y cantidad de imágenes. También construimos una muestra dirigida de 20 salidas del LoRA enriquecido para una auditoría exploratoria asistida por IA. Esta revisión no fue realizada por dermatólogos y sus tasas no estiman prevalencia clínica.

6. Resultados

6.1. Comparación VLM pareada

La Tabla 2 contiene todas las condiciones comparables por imagen. Sobre el objetivo enriquecido, LoRA sin RAG es mejor en cinco de seis métricas y eleva BERTScore de 0,680 a 0,738. RAG mejora modestamente al modelo base, pero reduce las métricas del adapter original. El entrenamiento RAG-aware recupera ROUGE-L y BERTScore respecto de LoRA+RAG, aunque permanece por debajo del LoRA sin RAG en chrF, token-F1 y sacreBLEU.

Sobre respuesta larga, el modelo base obtiene el mayor chrF y BERTScore. LoRA no reproduce la mejora observada con el target enriquecido, y RAG vuelve a degradar especialmente al adapter. Dado que cada variante usa una referencia diferente, la brecha entre targets describe facilidad de aprendizaje y alineación con la referencia, no superioridad clínica directa.

6.2. Recuperación frente a generación

La Tabla 3 compara retrieval y LoRA enriquecido a nivel caso. SBERT obtiene el mayor sacreBLEU, coherente con copiar una respuesta real cercana. LoRA logra mayor chrF corpus, chrF medio, ROUGE-L, token-F1 y BERTScore, lo que

sugiere mejor cobertura semántica aunque menor coincidencia exacta de n-gramas.

6.3. Costo y análisis de errores

Los entrenamientos pareados de LoRA tardaron 77,3 minutos para el target enriquecido y 78,9 para respuesta larga en una NVIDIA L4; los picos de VRAM fueron 6,73 y 5,11 GB. El adapter RAG-aware tardó 108,3 minutos y alcanzó 5,67 GB. Cada adapter ocupa aproximadamente 160 MB y ajusta 37,2 millones de parámetros (0,98 % del modelo).

En el score compuesto por fila, LoRA supera al modelo base en 96,5 % de las imágenes enriquecidas, pero solo en 39,2 % de las imágenes con respuesta larga. La ganancia enriquecida es mayor en referencias cortas: +0,153 frente a +0,061 en referencias de más de 60 palabras. Agregar RAG al LoRA mejora solo 33,8 % de las imágenes enriquecidas y 25,2 % de las largas. Estos patrones apoyan la hipótesis de que un target compacto y estable favorece la adaptación, mientras que los contextos de otros pacientes pueden inducir especificidad irrelevante.

La auditoría exploratoria de 20 casos enriquecidos etiquetó 3 respuestas como correctas, 9 como parciales y 8 como incorrectas; además señaló 9 recomendaciones no sustentadas y 2 potencialmente inseguras. La muestra fue seleccionada por modos de error y las etiquetas fueron asistidas por IA, por lo que estos números solo ilustran riesgos. Los ejemplos muestran diagnósticos plausibles pero equivocados, omisión de diferenciales relevantes y tratamientos no presentes en la referencia.

7. Discusión

La respuesta a RQ1 es condicionada: bajo el mismo cómputo, LoRA aprende mucho mejor el objetivo enriquecido que la respuesta más larga. La síntesis reduce longitud, redundancia y contradicciones de estilo, y convierte múltiples opiniones en una señal supervisada más estable. Sin embargo, las métricas se calculan contra referencias distintas; no demuestran que la síntesis sea médicamente más verdadera.

Para RQ2, la adaptación eficiente sí supera al modelo base y a retrieval en el target enriquecido, pero no constituye una mejora universal. En respuesta larga, el modelo base conserva mayor similitud semántica. La calidad del target parece dominar la utilidad del fine-tuning.

Target	Condición	BLEU	chrF _c	chrF _m	R-L	Tok-F1	BERT-F1
Enriquecido	Base	1,401	31,408	0,298	0,123	0,189	0,680
	Base + RAG	1,712	32,470	0,310	0,136	0,199	0,682
	LoRA	11,598	35,691	0,365	0,254	0,317	0,738
	LoRA + RAG	8,799	29,170	0,302	0,228	0,274	0,724
	LoRA RAG-aware	9,088	27,946	0,298	0,248	0,288	0,737
Respuesta larga	Base	0,624	21,977	0,211	0,083	0,110	0,646
	Base + RAG	0,609	21,226	0,202	0,083	0,107	0,642
	LoRA	0,299	14,474	0,168	0,081	0,092	0,619
	LoRA + RAG	0,078	10,541	0,121	0,041	0,033	0,560

Cuadro 2: Resultados en test por imagen ($n = 314$; 100 encuentros). BLEU y chrF_c son métricas corpus; las restantes son medias por fila. La negrita marca el mejor valor dentro de cada target.




Figura 1: BERTScore y token-F1 en las condiciones VLM pareadas. LoRA mejora con el target enriquecido, pero no con respuesta larga; RAG no revierte esa tendencia.

Método	BLEU	chrF _m	Tok-F1	BERT-F1
TF-IDF	8,266	0,286	0,256	0,716
E5-small	8,555	0,308	0,259	0,714
SBERT	8,795	0,309	0,269	0,720
LoRA VLM	5,022	0,368	0,314	0,737

Cuadro 3: Target enriquecido a nivel caso ($n = 100$). La fila LoRA agrega predicciones de las imágenes del encuentro sin selección oracle.

Para RQ3, RAG ofrece mejoras pequeñas al modelo base enriquecido, pero empeora los adapters cuando se agrega únicamente en inferencia. Entrenar con el prompt RAG reduce ese desajuste y recupera BERTScore, aunque todavía no supera a LoRA simple. Recuperar por similitud de pregunta no garantiza similitud clínica; los casos vecinos pueden aportar diagnósticos o tratamientos de otro paciente. Un paso futuro es recuperar con representaciones multimodales y filtrar evidencia por entidad diagnóstica, localización y morfología.

8. Conclusiones

Comparamos recuperación, inferencia zero-shot, QLoRA/LoRA y RAG para VQA dermatológico en español. El mejor resultado automático corresponde a Qwen2.5-VL-3B adaptado sobre respuestas enriquecidas sin RAG. La misma receta sobre res-

puestas originales largas no mejora al modelo base, y el contexto recuperado tiende a perjudicar a LoRA. Por lo tanto, diseñar un objetivo supervisado consistente es una decisión central, no un detalle de preprocesamiento. Los errores cualitativos impiden interpretar el sistema como asistente clínico listo para uso real.

Limitaciones

El test contiene 100 encuentros; las 314 imágenes no son observaciones independientes. No ejecutamos múltiples semillas ni intervalos de confianza agrupados por encuentro, por lo que las diferencias pequeñas no implican significancia estadística. El target enriquecido es sintético y puede consolidar errores de las respuestas originales o del LLM. La auditoría clínica es preliminar, dirigida y no fue validada por dermatólogos. Solo evaluamos Qwen2.5-VL-3B por restricciones de cómputo, un recuperador textual E5 para RAG y un único valor de k . La condición RAG-aware no se entrenó sobre respuesta larga. Finalmente, las métricas de similitud textual no miden seguridad, calibración ni validez diagnóstica.

Consideraciones éticas

Las consultas dermatológicas contienen información sensible y provienen de un dataset público preexistente; este trabajo hereda sus decisiones de anonimización y licencia. No intentamos identificar pacientes. El modelo puede producir diagnósticos o recomendaciones convincentes pero incorrectos, con riesgo de retrasar atención o inducir automedicación. Los artefactos se presentan exclusivamente para investigación y no deben usarse para diagnóstico ni tratamiento sin supervisión clínica, evaluación prospectiva y controles de privacidad.

Reproducibilidad

El repositorio versiona scripts, configuraciones, predicciones y métricas ligeras. Las imágenes, claves y adapters no se publican. Los datasets se reconstruyen con los scripts de `src/`; las corridas VLM usan semilla 42 y guardan configuración, historial, métricas y tiempos. El manuscrito se compila localmente con `latexmk -pdf main.tex` desde `paper/ac1`.

References

- Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibong Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, et al. 2025. Qwen2.5-VL technical report. *arXiv preprint arXiv:2502.13923*.
- Marie Bauer, Constantin Seibold, Jens Kleesiek, and Amin Dada. 2024. [IKIM at MEDIQA-M3G 2024: Multilingual visual question-answering for dermatology through VLM fine-tuning and LLM translations](#). In *Proceedings of the 6th Clinical Natural Language Processing Workshop*, pages 439–447. Association for Computational Linguistics.
- Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. 2023. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems*, volume 36, pages 10088–10115.
- Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2022. LoRA: Low-rank adaptation of large language models. In *International Conference on Learning Representations*.
- Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktaschel, Sebastian Riedel, and Douwe Kiela. 2020. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474.
- Chin-Yew Lin. 2004. ROUGE: A package for automatic evaluation of summaries. In *Text Summarization Branches Out*, pages 74–81. Association for Computational Linguistics.
- Maja Popović. 2015. [chrF: Character n-gram F-score for automatic MT evaluation](#). In *Proceedings of the Tenth Workshop on Statistical Machine Translation*, pages 392–395. Association for Computational Linguistics.
- Matt Post. 2018. [A call for clarity in reporting BLEU scores](#). In *Proceedings of the Third Conference on Machine Translation: Research Papers*, pages 186–191. Association for Computational Linguistics.
- Nils Reimers and Iryna Gurevych. 2019. [Sentence-BERT: Sentence embeddings using siamese BERT-networks](#). In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992. Association for Computational Linguistics.
- Jerrin Thomas, Sushvin Marimuthu, and Parameswari Krishnamurthy. 2024. [LTRC-IIITH at MEDIQA-M3G 2024: Medical visual question answering with vision-language models](#). In *Proceedings of the 6th Clinical Natural Language Processing Workshop*, pages 703–707. Association for Computational Linguistics.
- Liang Wang, Nan Yang, Xiaolong Huang, Linjun Yang, Rangan Majumder, and Furu Wei. 2024. Multilingual E5 text embeddings: A technical report. *arXiv preprint arXiv:2402.05672*.
- Wen-wai Yim, Asma Ben Abacha, Yajuan Fu, Zhaoyi Sun, Fei Xia, Meliha Yetisgen, and Martin Krallinger. 2024a. [Overview of the MEDIQA-M3G 2024 shared task on multilingual multimodal medical answer generation](#). In *Proceedings of the 6th Clinical Natural Language Processing Workshop*, pages 581–589. Association for Computational Linguistics.
- Wen-wai Yim, Yajuan Fu, Zhaoyi Sun, Asma Ben Abacha, Meliha Yetisgen, and Fei Xia. 2024b. [DermaVQA: A multilingual visual question answering dataset for dermatology](#). In *Medical Image Computing and Computer Assisted Intervention – MICCAI 2024*, volume LNCS 15005, pages 209–219. Springer Nature Switzerland.
- Tianyi Zhang, Varsha Kishore, Felix Wu, Kilian Q. Weinberger, and Yoav Artzi. 2020. BERTScore: Evaluating text generation with BERT. In *International Conference on Learning Representations*.